



GamuCare AI

Documentación técnica consolidada

Arquitectura, operación, seguridad, RAG y evaluación

Tipo de documento	Documento técnico
Versión del software	0.16.0-rc1
Autor	Marcos Ortiz
Fecha	Julio de 2026
Estado	Borrador final para revisión y entrega

Entorno académico y demostrativo. Todos los datos personales y clínicos son ficticios.



Control del documento

Versión	Fecha	Descripción
0.1	15/07/2026	Primera consolidación de documentación final.
0.2	15/07/2026	Ajuste al candidato v0.16.0-rc1.

Nota	Este documento describe el estado del candidato de entrega. Antes de etiquetar v1.0.0 solo deben introducirse correcciones documentales o fallos bloqueantes.
------	---



Índice

- 1 Visión general y alcance**
- 2 Requisitos y decisiones de diseño**
- 3 Arquitectura de la solución**
- 4 Perfiles y funciones**
- 5 Modelo de datos**
- 6 Módulos funcionales**
- 7 VetIA y arquitectura RAG**
- 8 Gobierno de fuentes**
- 9 Seguridad y auditoría**
- 10 Despliegue y configuración**
- 11 Observabilidad**
- 12 Backup, restauración y resiliencia**
- 13 Pruebas y evaluación**
- 14 Operación y mantenimiento**
- 15 Incidencias y resolución**
- 16 Limitaciones y trabajo futuro**
- A Anexos**



1. Visión general y alcance

GamuCare AI es un producto mínimo viable académico orientado a la gestión de planes de salud veterinarios. Integra la operativa de propietarios y mascotas, historiales clínicos ficticios, prestaciones incluidas en planes, pagos, renovaciones, avisos preventivos, paneles por perfil y un asistente documental llamado VetIA.

El sistema se ejecuta de forma local mediante Docker Compose. AWS queda expresamente fuera del alcance final. Todos los datos personales y clínicos utilizados en la demostración son ficticios y la aplicación no está certificada para uso clínico ni para explotación productiva.

Elemento	Alcance final
Despliegue	Local, Docker Desktop/WSL2 y Docker Compose
Usuarios	Clínica, personal, propietario y técnico
IA generativa	Ollama con variante gamucare-llm
Base vectorial	Qdrant
Persistencia	PostgreSQL
DevOps	Scripts, CI, pruebas, evidencias, backup y restore
Observabilidad	Prometheus, Grafana, Alertmanager y Blackbox Exporter
Fuera de alcance	AWS, alta disponibilidad y certificación clínica

2. Requisitos y decisiones de diseño

El diseño busca demostrar una solución de IA generativa integrada en una aplicación real, con base de datos vectorial, modelo local, trazabilidad, seguridad, pruebas y observabilidad. Se priorizó la reproducibilidad del entorno y la separación entre funciones clínicas y técnicas.


- Arquitectura desacoplada por servicios.
- Conocimiento especializado mediante RAG, sin fine-tuning.
- Autorización verificada en backend, no solo en la interfaz.
- Datos ficticios y minimización de información en logs.
- Versionado semántico, migraciones Alembic y documentación por release.
- Modelo local para evitar dependencia de una API externa.

Decisión	La versión candidata congela el alcance funcional. A partir de v0.16.0-rc1 solo deben aceptarse correcciones de errores, documentación y preparación de la entrega.
----------	---



3. Arquitectura de la solución

Arquitectura local de GamuCare AI



Despliegue mediante Docker Compose. AWS queda fuera del alcance final.

Figura 1. Arquitectura local del candidato de entrega.

El navegador accede a Nginx, que publica el frontend React y actúa como punto de entrada de la aplicación. FastAPI concentra la autorización, la lógica de negocio y la coordinación con PostgreSQL, Qdrant y Ollama. La monitorización se habilita mediante un perfil opcional de Docker Compose.

Servicio	Tecnología	Puerto host	Persistencia
web	React + Nginx	8080	imagen reconstruible
api	FastAPI	8000	logs en app_logs y datos montados
postgres	PostgreSQL 16	interno	postgres_data
qdrant	Qdrant	6333	qdrant_data
ollama	Ollama	11434	ollama_data
prometheus	Prometheus	9090	prometheus_data
grafana	Grafana	3000	grafana_data
alertmanager	Alertmanager	9093	alertmanager_data
blackbox-exporter	Blackbox Exporter	interno	sin volumen
postgres-exporter	PostgreSQL Exporter	interno	sin volumen

El compose actual no incorpora cAdvisor. Las métricas disponibles proceden de la API, Qdrant, PostgreSQL Exporter y las sondas HTTP de Blackbox Exporter.



4. Perfiles y funciones

La separación de perfiles evita mezclar la operación diaria con la administración técnica. El frontend adapta menús y rutas, pero FastAPI realiza la comprobación definitiva en cada endpoint y valida también la propiedad de los recursos.

Área	clinic	staff	owner	technical
Dashboard	global	global, lectura	solo propio	no
Propietarios y mascotas	CRUD	lectura	solo propias	no
Historial clínico	CRUD	lectura	visible y propio	no
Planes, pagos y renovaciones	gestión	lectura	propios y solicitud	no
Avisos preventivos	gestión	lectura	resumen propio	no
VetIA	sí	sí	contexto autorizado	no
Calidad de VetIA	no	no	no	sí
Validación MVP	no	no	no	sí
Wakyma	no	no	no	sí
Auditoría, seguridad y estado	no	no	no	sí

5. Modelo de datos

El esquema relacional se organiza en identidad y seguridad, operación veterinaria, planes LifeCare, prevención, IA y calidad, e integración. La cabecera de migración del candidato es 0009_system_evaluation.

Dominio	Entidades principales	Relación o finalidad
Identidad	users, refresh_sessions, audit_logs	rol, bloqueo, sesiones, trazabilidad
Veterinaria	owners, pets, clinical_events	propietario 1-N mascotas; mascota 1-N eventos
Planes	health_plans, plan_services, pet_plan_subscriptions, subscription_services, plan_installments	catálogo, vigencia, prestaciones y cobros
Renovación	renewal_requests	solicitud y resolución
Prevención	risk_rules, risk_alerts, alert_status_history	reglas, evidencias y ciclo de vida
IA	rag_documents, chat_sessions, chat_messages, rag_evaluation_runs	fuentes, conversación y calidad
Evaluación	system_evaluation_runs	resultado global del MVP
Integración	import_batches, import_batch_items	lotes Wakyma y resultados por registro

La baja de propietarios y mascotas es lógica. Los historiales indexados en Qdrant excluyen los datos de contacto del propietario. La auditoría evita almacenar contraseñas, tokens y textos clínicos completos.



6. Módulos funcionales

6.1 Datos de demostración

El entorno reconstruible contiene 15 propietarios, 25 mascotas, seis planes LifeCare y más de 200 eventos clínicos ficticios. Los eventos enriquecidos permiten demostrar recurrencias articulares, respiratorias, dermatológicas, auriculares, digestivas, de peso y renales.

6.2 Gestión clínica y comercial

- Alta, edición, baja lógica y reactivación de propietarios y mascotas.
- Registro de eventos clínicos con visibilidad diferenciada para el propietario.
- Asignación, cambio, cancelación y renovación de planes.
- Pago único o fraccionado entre 2 y 12 cuotas.
- Prestaciones periódicas, múltiples, ilimitadas, descuentos y beneficios.
- Dashboard con indicadores, agenda, tendencias y exportación CSV.

6.3 Avisos preventivos

El catálogo incluye 13 reglas preventivas con fuente y fecha de revisión. El motor evita duplicados, conserva evidencia, reabre avisos cuando reaparece la condición y puede resolverlos automáticamente cuando deja de cumplirse una regla autorresoluble.

6.4 Integración Wakyma simulada

El adaptador acepta JSON y CSV, valida sin modificar datos, procesa parcialmente los lotes, registra errores por elemento y aplica upsert mediante `external_id`. En la versión final la pantalla se reserva al perfil técnico para separar la importación y el diagnóstico de la operación clínica diaria.



7. VetIA y arquitectura RAG

Flujo de VetIA y arquitectura RAG



Figura 2. Pipeline de recuperación y generación de VetIA.

VetIA utiliza una variante de llama3.2:3b llamada gamucare-llm. El nombre identifica una configuración local creada mediante Modelfile; no implica entrenamiento ni ajuste de pesos. El prompt de sistema limita el ámbito, obliga a expresar insuficiencia de contexto y añade advertencias clínicas.

Parámetro	Valor
Modelo base	llama3.2:3b
Modelo de chat	gamucare-llm
Embeddings	nomic-embed-text
Temperatura	0.2
top_p	0.9
top_k	40
repeat_penalty	1.1
Contexto	4096 tokens
Colección Qdrant	gamucare_knowledge
Umbral mínimo	0.42
Candidatos	24
Top K documental	6



7.1 Decisiones explicables

Decisión	Significado
accepted	Existe evidencia suficiente para responder.
out_of_scope	La pregunta no pertenece al dominio veterinario y se rechaza antes de Qdrant.
low_score	Hay candidatos, pero no superan el umbral.
no_evidence	No existe evidencia utilizable.

Top score representa la similitud del mejor fragmento y no una probabilidad de respuesta correcta. MRR mide la posición media del primer resultado relevante.

7.2 Alcances y privacidad

- Documental: fuentes públicas y documentos locales.
- Clínico global: clinic y staff sobre historiales ficticios autorizados.
- Mascota: owner, clinic o staff con filtro por mascota y propiedad.
- El perfil technical no usa VetIA; administra calidad y estado técnico.

8. Gobierno de fuentes

El repositorio incorpora 17 documentos locales versionados y un catálogo de siete fuentes oficiales descargables. Tras una descarga completa pueden existir 24 documentos de referencia, además de fichas y eventos clínicos indexados desde PostgreSQL.

Organismo	Documento	Categoría	Formato	Idioma
WSAVA Vaccination Guidelines Group	Pautas para la vacunación de perros y gatos 2024	vaccination	PDF	es
American Animal Hospital Association (AAHA)	2023 AAHA Senior Care Guidelines for Dogs and Cats	senior_care	PDF	en
ESCCAP	Control of Vector-Borne Diseases in Dogs and Cats - GL5	vector_borne	PDF	en
FEDIAF - EuropeanPetFood	FEDIAF Nutritional Guidelines for Complete and Complementary Pet Food 2025	nutrition	PDF	en
International Renal Interest Society (IRIS)	IRIS Staging System for Chronic Kidney Disease	renal	HTML	en
Union Europea - YourEurope	Viajes con mascotas y otros animales en la Union Europea	travel	HTML	es
Ministerio de Agricultura, Pesca y Alimentación (MAPA)	Viajar con perros, gatos y hurones	travel	HTML	es

Cada descarga registra URL, fecha, tipo de contenido, tamaño, hash SHA-256, categoría, idioma y nivel de confianza. Los documentos completos de terceros no se redistribuyen en el ZIP del proyecto.

```
.\scripts\download-rag-sources.ps1 -Reindex
.\scripts\download-rag-sources.ps1 -Force -Reindex
```



9. Seguridad y auditoría

- Contraseña mínima de 12 caracteres con mayúscula, minúscula, número y carácter especial.
- Bloqueo de 15 minutos tras cinco intentos incorrectos.
- Access token de 30 minutos y refresh token de siete días.
- Cookie HttpOnly, SameSite=Lax en local y rotación del refresh.
- Revocación individual y global mediante token_version.
- Request ID común en respuesta, logs y auditoría.
- Redacción de contraseñas, JWT, cookies, contactos y textos clínicos.
- Errores 500 genéricos y página explícita de acceso denegado.

Seguridad	Las credenciales incluidas son exclusivamente de demostración. El archivo .env no debe subirse al repositorio.
-----------	--

10. Despliegue y configuración

La instalación recomendada se realiza en Windows 10/11 con Docker Desktop, WSL2 y, opcionalmente, GPU NVIDIA. Los modelos permanecen en el volumen ollama_data y no se descargan de nuevo al reconstruir la API o el frontend.

```
.\scripts\setup-gpu.ps1
.\scripts\setup-cpu.ps1
.\scripts\upgrade-v0.16-rc1.ps1
```


URL	Uso
http://localhost:8080	Aplicación
http://localhost:8000/docs	OpenAPI
http://localhost:6333/dashboard	Qdrant
http://localhost:3000	Grafana
http://localhost:9090	Prometheus
http://localhost:9093	Alertmanager

Las variables críticas incluyen DATABASE_URL, JWT_SECRET, OLLAMA_CHAT_MODEL, OLLAMA_EMBED_MODEL, QDRANT_COLLECTION, RAG_MIN_SCORE y las credenciales de Grafana. APP_ENV=production exige revisar TLS, cookies seguras y secretos.



11. Observabilidad

Observabilidad y recuperación



La observabilidad detecta y explica fallos; no reinicia servicios automáticamente.

Figura 3. Flujo de observabilidad y recuperación.

Regla	Condición
GamuCareServiceDown	probe_success = 0 durante 2 minutos
GamuCarePostgresExporterDown	pg_up = 0 durante 2 minutos
GamuCareApiHighErrorRate	más del 5 % de respuestas 5xx durante 5 minutos
GamuCareApiHighLatency	P95 superior a 2 segundos durante 5 minutos
GamuCareOllamaErrors	errores de Ollama en 10 minutos
GamuCareQdrantErrors	errores de búsqueda en Qdrant en 10 minutos

Alertmanager agrupa y muestra alertas en el receptor local-dashboard. No existe un canal de correo, Slack o Teams configurado por defecto.



12. Backup, restauración y resiliencia

- backup.ps1 crea copia de PostgreSQL, Qdrant y metadatos.
- verify-backup.ps1 comprueba integridad y estructura.
- restore.ps1 restaura PostgreSQL y Qdrant; -RestoreData incluye documentos e informes.
- resilience-test.ps1 detiene de forma controlada Qdrant y Ollama, verifica el estado down y confirma la recuperación.
- Los modelos de Ollama no se copian porque pueden descargarse de nuevo.

```
.\scripts\backup.ps1
.\scripts\verify-backup.ps1 -BackupPath .\backups\gamucare-AAAAMMDD-HHMMSS
.\scripts\restore.ps1 -BackupPath .\backups\gamucare-AAAAMMDD-HHMMSS -Force
```

13. Pruebas y evaluación

Evidencia	Cobertura
Pytest	76 pruebas backend registradas
Cobertura	60 % global registrado
Permisos	22 accesos permitidos/denegados
RAG	23 casos en rag_cases_v2
Aceptación MVP	16 criterios
Avisos	dataset controlado y matriz de confusión
Smoke test	web, API, dependencias y monitorización
CI	backend, frontend, cobertura, JUnit y sintaxis PowerShell

Calidad de VetIA separa retrieval de generation. Retrieval comprueba la búsqueda sin llamar al LLM. Generation añade 23 llamadas secuenciales al modelo y puede tardar. Si la petición se interrumpe, la ejecución puede quedar huérfana en running; el registro debe cerrarse como failed y repetirse.

```
.\scripts\generate-evidence.ps1 -IncludeMonitoring -IncludePermissions
.\scripts\release-validation.ps1 -IncludeMonitoring
.\scripts\test-permissions.ps1
```

14. Operación y mantenimiento

Tarea	Comando
Arranque GPU	.\scripts\start-gpu.ps1
Arranque CPU	.\scripts\start-cpu.ps1
Parada	.\scripts\stop.ps1
Monitorización	.\scripts\start-monitoring.ps1
Reindexación	docker compose ... exec -T api python -m app.rag.ingest
Reset demo	.\scripts\reset-demo.ps1
Evidencias	.\scripts\generate-evidence.ps1 -IncludeMonitoring -IncludePermissions



15. Incidencias y resolución

Síntoma	Causa probable	Acción
API no está ready	PostgreSQL, Qdrant u Ollama no disponibles	Revisar /health/dependencies y logs.
Calidad aparece running	evaluación generation interrumpida	marcar ejecución huérfana como failed y repetir retrieval.
Fuentes no aparecen	no descargadas o no reindexadas	ejecutar download-rag-sources.ps1 -Reindex.
Top score en pregunta no veterinaria	filtro de dominio no aplicado o versión antigua	reconstruir API y verificar v0.16.0-rc1.
Grafana sin datos	perfil monitoring no iniciado	start-monitoring.ps1 y revisar targets.
Alertmanager vacío	no hay alertas activas	detener temporalmente un servicio para una prueba controlada.
PowerShell NativeCommandError	salida stderr de Docker tratada como error	usar scripts incluidos y comprobar LASTEXITCODE.

16. Limitaciones y trabajo futuro

- Validación técnica sobre datos ficticios, no validación clínica.
- Sujeto a cambios de URLs o condiciones de uso.
- Evaluación generation síncrona; se recomienda convertirla en trabajo en segundo plano con progreso.
- Alertmanager solo dispone de receptor local.
- Sin alta disponibilidad, TLS integrado, escalado horizontal ni despliegue cloud.
- La integración Wakyma es simulada y no usa una API real ya que el servicio tenía coste recurrente.
- AWS queda fuera del alcance final; podría estudiarse como evolución, no como requisito de entrega.

Anexo A. Usuarios de demostración

Perfil	Usuario	Contraseña
clinic	clinic@gamucare.local	GamuCare123!
staff	staff@gamucare.local	GamuCare123!
technical	technical@gamucare.local	GamuCare123!
owner	owner01@example.test	GamuCare123!

Anexo B. Checklist de entrega

- Ejecutar smoke test y validación de release.
- Completar Calidad de VetIA en retrieval.
- Completar Validación del MVP.
- Generar evidencias con monitorización y permisos.
- Verificar .gitignore y ausencia de .env, backups, logs, evidence y documentos externos.
- Subir código, documentación y tag de la versión.
- Revisar la memoria y sustituir el autor o datos académicos si procede.