



ORtiz

GamuCare AI

Memoria del Trabajo Fin de Máster

GamuCare AI: plataforma local de gestión veterinaria con asistente RAG, seguridad y observabilidad

Tipo de documento	Memoria académica
Versión del software	0.16.0-rc1
Autor	Marcos Ortiz
Fecha	Julio de 2026
Estado	Borrador final para revisión y entrega

Entorno académico y demostrativo. Todos los datos personales y clínicos son ficticios.



Resumen

GamuCare AI es un producto mínimo viable que integra la gestión de planes preventivos veterinarios con un asistente de inteligencia artificial generativa basado en recuperación aumentada por generación. La solución se ejecuta localmente mediante Docker Compose y combina React, FastAPI, PostgreSQL, Qdrant y Ollama. Incluye cuatro perfiles de acceso, gestión de propietarios y mascotas, historiales ficticios, planes, pagos, renovaciones, avisos preventivos, integración Wakyma simulada, auditoría, monitorización, backup y evaluación formal. VetIA utiliza un modelo local configurado, no fine-tuneado, y recupera evidencia de documentos versionados y registros clínicos ficticios autorizados. El MVP demuestra una arquitectura completa y reproducible, aunque no pretende sustituir el criterio veterinario ni constituye una plataforma de producción.

Palabras clave: inteligencia artificial generativa, RAG, base de datos vectorial, veterinaria, Docker, observabilidad, seguridad.



Índice

- 1 Introducción**
- 2 Objetivos y alcance**
- 3 Metodología y evolución**
- 4 Arquitectura**
- 5 Diseño funcional**
- 6 VetIA y RAG**
- 7 Seguridad y protección de datos**
- 8 DevOps y observabilidad**
- 9 Evaluación y resultados**
- 10 Limitaciones**
- 11 Conclusiones y trabajo futuro**
- 12 Referencias**



1. Introducción

Las clínicas veterinarias gestionan información clínica, servicios preventivos, vencimientos, planes de salud y pagos. Cuando estos elementos se encuentran dispersos, aumenta el esfuerzo administrativo y resulta más difícil detectar recurrencias o explicar de forma trazable por qué una mascota requiere seguimiento. Al mismo tiempo, los modelos generativos pueden facilitar el acceso a la información, pero una respuesta sin fuentes o sin control de permisos introduce riesgos de alucinación y exposición de datos.

GamuCare AI se plantea como un MVP académico que une la operación veterinaria y una capa de IA generativa local. La solución no intenta diagnosticar. Su objetivo es organizar la información, recuperar evidencia y demostrar cómo integrar un modelo fundacional, una base vectorial, seguridad, pruebas, logging, monitorización y automatización en un producto coherente.

2. Objetivos y alcance

2.1 Objetivo general

Diseñar e implementar una plataforma local y reproducible para gestionar planes preventivos veterinarios y consultar documentación e historiales ficticios mediante un asistente RAG con fuentes, permisos y evaluación.

2.2 Objetivos específicos

- Construir una aplicación web responsive con API y persistencia relacional.
- Modelar propietarios, mascotas, historiales, planes, servicios, cuotas y renovaciones.
- Detectar avisos preventivos con reglas trazables.
- Integrar Qdrant y un modelo local ejecutado por Ollama.
- Aplicar autorización por rol y propiedad del recurso.
- Incorporar auditoría, sesiones, logging, métricas, alertas y backups.
- Definir datasets de prueba y una validación formal del MVP.
- Automatizar la instalación y la generación de evidencias.

2.3 Alcance final

Incluido	Excluido
Despliegue local con Docker Compose	AWS y otros despliegues cloud
Datos ficticios de demostración	Datos reales de pacientes
Modelo local y RAG	Fine-tuning o entrenamiento del modelo
Wakyma simulado	Conexión con API comercial real
Monitorización local	Alta disponibilidad y operación 24x7
Validación técnica	Certificación clínica




3. Metodología y evolución

El desarrollo se realizó de forma incremental mediante versiones semánticas. Cada versión incorporó cambios funcionales, técnicos, migraciones, pruebas, instrucciones de actualización y rollback. La evolución comenzó con un MVP básico y fue añadiendo autorización, RAG clínico, pagos, ciclo de vida de planes, prevención, calidad del RAG, dashboards, integración, seguridad, evaluación, monitorización, perfil técnico y cierre documental.

Versión	Hito principal
0.1-0.2	MVP, compilación y roles iniciales
0.3-0.4	RAG clínico, propietario y pagos
0.5-0.6	Ciclo de planes y avisos preventivos
0.7-0.8	Calidad RAG y dashboards
0.9-0.10	Wakyma, seguridad y auditoría
0.11-0.12	Validación del MVP y observabilidad
0.13-0.14	Perfil técnico, filtro de dominio y corpus externo
0.15	Endurecimiento, permisos y resiliencia
0.16-rc1	Datos demo, evidencias y congelación del alcance

4. Arquitectura

Arquitectura local de GamuCare AI



Despliegue mediante Docker Compose. AWS queda fuera del alcance final.

Figura 1. Arquitectura del MVP local.

La interfaz React se publica mediante Nginx. FastAPI centraliza la lógica de negocio y se comunica con PostgreSQL, Qdrant y Ollama. PostgreSQL conserva los datos estructurados; Qdrant almacena vectores del corpus y de los historiales ficticios; Ollama ejecuta el modelo generativo y el modelo de embeddings. Prometheus, Grafana, Alertmanager, PostgreSQL Exporter y Blackbox Exporter completan la observabilidad.

La contenerización facilita reproducir la solución sin instalar Python, Node.js, PostgreSQL o los modelos directamente en el equipo. Los volúmenes preservan datos y modelos entre reconstrucciones.



5. Diseño funcional

5.1 Datos y planes

El dataset contiene 15 propietarios, 25 mascotas y más de 200 eventos clínicos ficticios. Los planes LifeCare se organizan en Baby, Active y Total para perros y gatos. Cada suscripción genera prestaciones, fechas previstas y un calendario de pago único o fraccionado.

5.2 Perfiles

Perfil	Responsabilidad
clinic	gestión completa de la operación clínica y comercial
staff	consulta global sin modificación
owner	acceso a sus mascotas, servicios, pagos y VetIA autorizada
technical	calidad, validación, Wakyma, auditoría, seguridad y estado técnico

El perfil técnico se introdujo para que los usuarios funcionales no visualicen elementos de evaluación, seguridad u observabilidad. El backend verifica siempre el rol y la pertenencia del recurso.

5.3 Prevención e integración

El motor de prevención utiliza 13 reglas versionadas. Conserva evidencia, evita duplicados, permite revisión y resolución, y reabre avisos cuando la condición reaparece. La integración Wakyma es un adaptador simulado para JSON y CSV que valida, procesa parcialmente y registra cada lote con checksum.

6. VetIA y RAG

Flujo de VetIA y arquitectura RAG



Figura 2. Recuperación aumentada por generación.

VetIA emplea llama3.2:3b como modelo base y crea la variante gamucare-llm mediante un Modelfile. Se ajustan el prompt de sistema y parámetros de inferencia, pero no se realiza fine-tuning. El conocimiento veterinario se proporciona en cada consulta mediante evidencia recuperada.

Antes de buscar, el sistema comprueba permisos y aplica un filtro de dominio. Esta decisión solucionó falsos positivos como preguntas de cultura general o búsquedas informáticas que contenían la palabra historial. Si la consulta es válida,



nomie-embed-text genera el vector, Qdrant devuelve candidatos y un reranking combina similitud, coincidencia léxica y metadatos. La respuesta utiliza citas F0, F1, etc.

Decisión	Interpretación
accepted	evidencia suficiente
out_of_scope	pregunta no veterinaria, sin consultar Qdrant
low_score	candidatos por debajo del umbral
no_evidence	ausencia de evidencia útil

El corpus del repositorio incluye 17 documentos locales y un catálogo de siete fuentes oficiales descargables, por lo que puede alcanzar 24 documentos de referencia. También se indexan fichas y eventos ficticios, filtrados por perfil.


7. Seguridad y protección de datos

La seguridad se diseñó en varias capas: política de contraseñas, bloqueo temporal, access token de 30 minutos, refresh token rotado, revocación de sesiones, autorización por rol y propiedad, cabeceras Nginx, errores trazables y auditoría con request_id.

La aplicación evita registrar contraseñas, JWT, cookies, teléfonos, direcciones y textos clínicos completos. Los datos de demostración son ficticios y el archivo .env queda fuera de Git. Estas medidas reducen el riesgo, aunque un despliegue productivo requeriría TLS, secretos gestionados, revisión legal y pruebas de seguridad adicionales.

8. DevOps y observabilidad

Observabilidad y recuperación



La observabilidad detecta y explica fallos; no reinicia servicios automáticamente.

Figura 3. Monitorización y recuperación.

Los scripts PowerShell automatizan instalación, actualización, ingesta, pruebas, backup, restore, resiliencia y generación de evidencias. El pipeline CI compila frontend y backend, ejecuta pruebas y valida la sintaxis de scripts en Windows.

Prometheus recoge métricas de FastAPI, Qdrant, PostgreSQL Exporter y Blackbox Exporter. Grafana muestra los paneles y Alertmanager agrupa alertas por disponibilidad, errores y latencia. El receptor es local; no se configuró un canal externo. Los logs JSON de la API se rotan y cada petición incorpora un request_id.



9. Evaluación y resultados

La evaluación combina pruebas automatizadas, matriz de permisos, dataset de avisos preventivos, Calidad de VetIA, criterios de aceptación, rendimiento y observabilidad. La release registra 76 pruebas backend superadas, una cobertura global del 60 %, 22 comprobaciones de permisos, 23 casos RAG y 16 criterios de aceptación.

La Calidad de VetIA separa retrieval y generation. Retrieval mide si se recupera la evidencia correcta y calcula métricas como hit rate, MRR, rechazo y latencia. Generation añade la respuesta de Ollama y comprueba citas y uso del contexto. Top score se interpreta como similitud, no como probabilidad de acierto.

Durante la validación se detectaron consultas veterinarias que requerían reindexación y dos falsos positivos fuera de dominio: la capital de Australia y la reparación de placas base. La reindexación solucionó los casos documentales y el filtro de dominio corrigió los falsos positivos. Este proceso demuestra el valor de utilizar un dataset versionado y no depender únicamente de ejemplos manuales.

La validación no demuestra eficacia diagnóstica. Demuestra que el software cumple criterios técnicos controlados, respeta permisos, recupera evidencia y puede detectar fallos operativos.

10. Limitaciones

- Datos y casos clínicos ficticios.
- Corpus acotado y dependiente de fuentes externas.
- Modelo de 3B parámetros, adecuado para hardware limitado pero con capacidad inferior a modelos mayores.
- Evaluación generation síncrona y susceptible de quedar huérfana si la petición se interrumpe.
- Wakyma simulado, sin API real.
- Alertmanager sin notificación externa.
- Sin alta disponibilidad ni despliegue cloud.
- No certificado para diagnóstico, tratamiento o producción.

11. Conclusiones y trabajo futuro

GamuCare AI demuestra que es posible construir una solución de IA generativa completa y reproducible en local, integrando base relacional, base vectorial, modelo fundacional, seguridad, auditoría, pruebas y observabilidad. El RAG aporta trazabilidad y permite separar el conocimiento documental de los pesos del modelo. La incorporación del perfil técnico mejora la separación de responsabilidades y facilita defender el MVP ante un evaluador.

Como trabajo futuro se propone ejecutar las evaluaciones en segundo plano con progreso, ampliar el corpus y su actualización, configurar notificaciones externas, integrar una API veterinaria real, reforzar accesibilidad y pruebas end-to-end, y estudiar un despliegue productivo con TLS, gestión de secretos, alta disponibilidad y cumplimiento normativo. Estas mejoras no forman parte del alcance final del TFM.



12. Referencias

Las fuentes veterinarias oficiales se mantienen en `data/rag_sources/sources.json`. El catálogo incluye WSAVA, AAHA, ESCCAP, FEDIAF, IRIS, Unión Europea y MAPA. Las tecnologías principales son Docker, FastAPI, PostgreSQL, Qdrant, Ollama, React, Prometheus, Grafana y Alertmanager.

Organismo	Referencia
WSAVA Vaccination Guidelines Group	Pautas para la vacunacion de perros y gatos 2024
American Animal Hospital Association (AAHA)	2023 AAHA Senior Care Guidelines for Dogs and Cats
ESCCAP	Control of Vector-Borne Diseases in Dogs and Cats - GL5
FEDIAF - EuropeanPetFood	FEDIAF Nutritional Guidelines for Complete and Complementary Pet Food 2025
International Renal Interest Society (IRIS)	IRIS Staging System for Chronic Kidney Disease
Union Europea - Your Europe	Viajes con mascotas y otros animales en la Union Europea
Ministerio de Agricultura, Pesca y Alimentacion (MAPA)	Viajar con perros, gatos y hurones